

PoC 報告

変圧器 油温予測の技術検証

ETTデータセットを用いて、油温の将来予測が
運用・保全判断にどこまで価値を出せるかを検証した

検証対象：ETT_{h1} / ETT_{h2}（1時間粒度・2016年7月～2018年6月）

追加データ：Open-Meteo Historical Weather API（ERA5 再解析）

価値の源泉は予測精度の向上ではなく、用途の絞り込みと外気温データの接続

結論① 精度改善は限定的

+0.5%

24時間先の予測で、159個の特徴量を使った学習モデルが「今と同じ温度」と言い張るだけの手法に対して得た改善幅。1週間先でも上限は+16.8%

結論② 異常検知の基準線は成立する

R^2 0.75

油温センサを一切使わず、負荷＋外気温だけで油温を推定した精度（ETTh2）。負荷のみでは $R^2=-0.02$ で平均予測と同等だった

結論③ 欠けていた変数は外気温

$r = 0.96$

外気温と油温の相関。データに含まれる負荷6変数の相関は最大0.22。最も効く変数が最初から入っていなかった

この結果をどう読むか

油温は自己相関がきわめて高く（1時間前との相関0.994）、直近値をそのまま返す単純な手法が強い基準線になる。ここを起点にすると、モデルの巧拙で得られる上積みは小さい。

それでも価値が出る2つの用途

- **異常検知の基準線**：「この条件ならこの温度が正常」を推定し、実測との乖離で異常を検出する
- **高温予兆の警報**：目的関数を運用指標に合わせると、1週間先の高温検知率は16%→78%になる

次に必要なもの

- 気象データ（実測＋予報）の接続
- 計測系の素性確認（記録分解能・機器改修履歴）
- 台数を増やした再検証

精度ではなく運用上の2つの問いに分けた検証設計

タスクA ナウキャスト（同時刻推定）

問い：油温計を見ずに、いま油温が何°Cのはずかを当てられるか

入力：同時刻を含む負荷6変数と外気温。油温の履歴は一切使わない

用途：センサ故障時の代替値／「この条件ならこの温度が正常」という基準線を作り、実測との乖離で異常を検出する

タスクB フォーキャスト（将来予測）

問い：h時間後の油温を当てられるか（ $h = 1 / 24 / 168$ ）

入力：時刻tまでに観測済みの全変数（油温の履歴を含む）


用途：予防保全。高温域に入る前に点検・負荷抑制の判断材料を出す

課題文の但し書きの解釈

「 $t=T$ の油温を予測する際には、 $t=T$ での特徴量を使用して良い」——この許可はタスクAでこそ本質的に効く。同時刻の負荷を使えるからこそ「今この瞬間の正常温度」を推定でき、異常検知の基準線が成立する。タスクBでは同時刻の情報は自明に利用可能なので、この但し書きは制約の緩和として機能しない。そこで両タスクを分けて検証し、許可の効き方を切り分けた。

欠損・重複ゼロの一方で、前処理を要する箇所が3点

負荷は0なのに油温は変動し続ける＝欠測のゼロ埋め



① 欠測のゼロ埋め (58時間)

2016/12/5 09:00～12/7 18:00、負荷6変数がすべて厳密に0。同区間で油温だけは $-4.1 \sim 15.3^{\circ}\text{C}$ の範囲で変動を続けている。負荷ゼロで油温が動くのは物理的に説明がつかず、実測ではなく埋め値と判断した。

対処：該当区間を欠測として扱い、線形補間したうえで学習・評価の対象から除外。ゼロのまま移動平均に流すと前後数日ぶんの特徴量まで汚染される。

② 記録分解能の違い


ETTh1の油温は 0.07°C 刻みに量子化されており、2年間で669種類の値しか取らない。ETTh2は 0.0005°C 刻みで1,628種類。同じ「油温」でも計測系が異なる。

③ 系列の非定常性

ETTh1は2年間で水準が大きく低下（次ページ）。学習期間と評価期間で分布が異なる。

ETTh1は夏のピークが2年で36°C→21°C。季節性では説明できないレベルシフト

ETTh1は同月比で毎年 5~15°C低下、ETTh2は年による差がほぼない



事実

ETTh1は全12か月で前年同月を下回る（7月 -12.8°C、8月 -15.0°C）。一方ETTh2の前年差は±2°C程度で横ばい。同じ期間・同じ省内の2台で挙動が真逆になっている。

負荷では説明できない


同期間、ETTh1の負荷HUFLは増加している（2017年1月 8.97→2018年1月 10.86）。負荷が増えて油温が下がる以上、冷却系の改修・機器更新・計測系の変更といった系列の外側の要因を疑うべきだが、データからは特定できない。

モデリングへの影響


学習期間の平均16.6°Cに対し評価期間は8.6°C。油温の絶対値を学習したモデルは評価期間で系統的に外す。特に勾配ブースティング木は学習データの範囲外へ外挿できない。→ 予測対象を差分に変える設計判断につながる (p.7)

油温は自己履歴が支配的。同時刻の負荷による説明力は最大 $r=0.22$

1時間前との相関0.994、1週間前でも0.83~0.87=自己履歴が主要な情報源



同時刻の負荷はOTの水準を最大 $r=0.22$ しか説明せず、変化量では相関が消える



自己相関がきわめて高い

1時間前との相関 0.994、24時間前 0.94、1週間前でも 0.83~0.87。「直近値をそのまま返す」だけで強力な基準線になることを意味する。これを超えられるかが本PoCの実質的な争点になった。

負荷の説明力が想定より低い


同時刻の相関は最大でHULLの0.22。さらに1階差分をとると相関はほぼ消える ($-0.07 \sim 0.03$)。水準の見かけ上の相関は共通の季節変動によるもので、変化の連動はない。

ここから立てた仮説


油温 $\equiv$ 外気温 + 負荷による温度上昇、という物理を踏まえると、最も効くはずの変数がデータに入っていない。日内パターン（早朝に最低・午後に最高）も外気温の形そのもの。→ 外部データで検証 (p.10)

EDAで得た3つの性質に対する設計上の対処

データの性質	設計上の対処	理由
レベルシフト 学習16.6℃ / 評価8.6℃	予測対象を差分 $\Delta = OT(t+h) - OT(t)$ にする	絶対値を学習すると評価期間で系統誤差が出る。勾配ブースティング木は学習範囲外へ外挿できないため致命的になる。深層モデル側は窓ごとの可逆正規化（RevIN）で同じ効果を得ている
季節による難易度の差	expanding-window で4分割し全季節を評価	最後の4か月だけで評価すると春～初夏の性能しか見えない。学習期間を伸ばしながら4か月ずつ評価し、結論が特定の季節に依存しないことを確認する
欠測のゼロ埋め	該当58時間を検出して除外	学習・評価の両方から外す。窓や予測先に区間が重なるサンプルも落とす
自己相関が支配的	Persistenceを常に併走させ、これを超えたかで評価する	絶対誤差だけを見ると「MAE 0.5℃」は高精度に見える。単純手法との差分で語らなければ、機械学習を入れる判断ができない



基準線を明確に上回るのは1週間先のみ。24時間先はほぼ横並び



ETTh1 の MAE (°C・4分割平均)

モデル	1h	24h	168h
Persistence	0.552	1.933	2.970
SeasonalNaive	0.742	2.967	5.085
Ridge	0.621	3.059	5.297
PatchTST	0.550	1.975	2.763
DLinear	0.544	1.868	2.761
LightGBM	0.526	1.925	2.621
LightGBM+外気温	0.518	1.851	2.469

読み取れること

- 24時間先の上回り幅は4.2%で誤差の範囲
- 1週間先は16.8%改善。長期ほど学習の価値が出る
- Ridge・SeasonalNaiveは基準線を大きく下回る

Persistence＝「h時間後も現在と同じ温度」と予測する手法。SeasonalNaive＝「前日同時刻の変化が繰り返す」と仮定する手法

深層モデルはこのデータ規模で優位性なし。Transformer系は計算コスト14倍で精度も下回る結果

ETTh1・24時間先の比較			
モデル	MAE	学習時間	パラメータ
LightGBM+外気温	1.851	14秒	—
DLinear	1.868	3秒	688
LightGBM	1.925	7秒	—
Persistence	1.933	0秒	0
PatchTST	1.975	100秒	106,319

なぜこうなるか

学習に使える有効データは1時間粒度で約17,000点。Transformerが表現力を発揮するには少ない。加えて系列の支配的な構造が「直近値への強い依存+日周期」という単純なもので、**長距離の依存関係を捉える機構が活きる場面が乏しい**。

DLinearがPatchTSTを上回るのは、線形分解モデルが長期予測ベンチマークでTransformerを上回るという既報（Zeng et al., 2023）と整合する。

意思決定

現時点で深層モデルへの投資は推奨しない。

- 精度で勝てていない
- 推論基盤・再学習運用のコストが増える
- 特徴量重要度のような説明手段が使いにくく、保全現場の納得を得にくい



ただし**データ量が桁で増える場合（多数の変圧器を横断学習する等）は再評価に値する。**

実装上の補足

DLinear・PatchTSTはいずれも窓ごとの可逆正規化（RevIN）を入れており、表形式モデル側で差分を予測しているのと同じ非定常対策を効かせている。この処理を外すと両モデルとも大きく劣化する。／ 学習時間はApple M系GPU（MPS）での実測値。


油温を最も説明する変数は外気温 (r=0.96)。データセットには非収録

油温を最も説明する変数は外気温 (r=0.96) で、これはデータに入っていないかった



出典：Open-Meteo Historical Weather API (ERA5 再解析, CC BY 4.0 / Copernicus Climate Change Service) <https://open-meteo.com/en/docs/historical-weather-api> / ETDatasetは観測地点を「中国のある省の2地域」としか公開していないため、気候帯を広くとった16都市の気温との整合度 (日次相関・季節同期を除いた残差相関・日内/月内/年の相関の平均) で地点を推定した。武漢0.921・南京0.920が同点上位

外気温の追加により油温を用いない推定で $R^2=0.75$ 。異常検知の基準線として成立



ナウキャストの精度（油温の履歴を一切使わない）

入力	ETTh1 MAE	ETTh2 MAE	ETTh2 R ²
平均を答えるだけ	6.76	10.18	-1.51
負荷6変数のみ	6.01	6.43	-0.02
負荷+外気温	5.07	3.23	0.75

運用上の意味

負荷だけでは平均を答えるのと同じ ($R^2=-0.02$) だったものが、外気温を足すと分散の75%を説明できるようになる。

これは「この負荷・この外気温なら油温は何℃が正常か」という基準線が引けることを意味する。実測との乖離を監視すれば、固定閾値では不可能な季節・負荷条件によらない異常検知が成立する。

ETTh1で成立しない理由

ETTh1は $R^2=-1.75$ と依然として実用水準にない。p.5で示した2年間のレベルシフトが外気温で説明できないため。機器側の改修や計測系の変更が疑われ、その情報なしには基準線を引けない。2台で結論が割れること自体が、導入前に台ごとの素性確認が要ることを示している。

精度指標で最良のモデルが、警報の用途では基準線を下回る結果

24時間先の高温イベント検知（ETTh1）

モデル	MAE	再現率	適合率	F1
LightGBM (MAE最適化)	1.840	0.314	0.602	0.388
Persistence	1.933	0.439	0.491	0.463
SeasonalNaive	2.967	0.702	0.319	0.439

なぜ逆転するか

MAEを最小化する学習では、モデルは自信のない場面で平均寄りの無難な値を返すのが最適になる。その結果、閾値を超える「尖った予測」が出なくなり、見逃し（FN）が640件まで増えた。

精度指標と運用指標は同じ方向を向いていない。℃単位の誤差0.09℃の改善は保全判断を何も変えないが、再現率0.44→0.31の悪化は「見逃しが4割増える」ことを意味する。

評価設計で修正した点


当初は高温イベントの閾値を「学習期間の95パーセンタイル」で固定していたが、p.5のレベルシフトにより評価期間で該当イベントが1件も発生しないという不具合が起きた。

そこで「予測時点から見た直近30日の95パーセンタイル」という時点ごとに動く閾値に変更した。時刻tまでの観測しか使わないため実運用でもそのまま計算でき、「平常時より明確に高い」を季節によらず定義できる。

この発見の意味

PoCの評価指標をMAEだけに置いていたら、「LightGBMが最良」という誤った結論を報告していた。運用でどう使うかを決めてから指標を決める必要がある。次ページはこの発見を受けた打ち手。

目的関数を運用指標に合わせることで、1週間先の高温検知は16%→78%へ



やったこと

損失関数を絶対誤差から分位点損失に替え、条件付き分布の中央値ではなく上側を予測させた。「平均的に何℃か」ではなく「高い方に振れるとすれば何℃か」を答えるモデルになる。
実装上の変更は目的関数の指定のみで、特徴量もデータ分割も同一。


1週間先の交換レート (ETTh1)

設定	MAE	再現率	誤報率
Persistence	2.970	0.160	6.2%
分位点 0.5	2.494	0.178	2.5%
分位点 0.7	2.781	0.368	8.3%
分位点 0.8	3.028	0.469	12.5%
分位点 0.9	3.997	0.779	33.2%

PoCの成果物として渡すもの

最良の1モデルではなく、この交換レートの表そのものを意思決定の材料として提示する。
「見逃し1件のコスト」と「空振り点検1件のコスト」の比が分かれば、分位点は一意に決まる。その比を持っているのは保全部門であってモデル側ではない。

同一手法でも2台で改善幅は+6%と+57%。1台の検証では判断困難



1時間先予測の比較

変圧器	Persistence	最良モデル	改善
ETTh1	0.552	0.518	+6.2%
ETTh2	0.929	0.401	+56.9%

差の原因（推定）

記録分解能。ETTh1の油温は0.07℃刻みに量子化されており、1時間で動く量（中央値0.28℃）に対して刻みが粗い。**Persistenceの誤差の相当部分が量子化ノイズ**で、これは学習で減らせない。
ETTh2は0.0005℃刻みで滑らかに記録されており、短期の連続的な変化を学習できる。

導入判断への含意

- 「ETTで検証したから自社設備でも効く」とは言えない。計測系の仕様が結果を左右する
- 導入前に確認すべきは、モデルの選択肢ではなく**記録分解能・サンプリング周期・欠測の扱い**
- ナウキャストもETTh2で成立しETTh1で不成立。台ごとの素性確認が前提

検証の妥当性を守るための選択と、コスト対効果による見送りの判断

採った選択		あえて採らなかった選択	
判断	理由	見送った案	理由
予測対象を差分にする	レベルシフトへの対処。木モデルは学習範囲外へ外挿できない	ホライズン一括の系列出力	ホライズンごとに独立して学習する方式を採用。用途（1時間先＝監視／1週間先＝計画）で必要な指標も許容誤差も異なり、個別に最適化・評価できる形を優先した
ナウキャストで油温履歴を禁止する	油温のラグを入れると相関0.994の変数が支配し、「負荷から推定できるか」という問い自体が測れなくなる	全期間統計での正規化	評価期間の情報が学習に混入する。分割ごとに閉じた統計のみ使用
expanding-window 4分割	最後の4か月だけでは春～初夏の性能しか見えない。結論が季節に依存しないことを確認する	ETTm（15分粒度）を主軸にする	ETTmはETTmの毎正時サブサンプルで同一系列であることを確認済み。粒度を上げてても支配的な構造は変わらず、計算コストが4倍になる
学習末尾にギャップを空ける	学習行のターゲットが評価区間に食い込むリークを防ぐ	深層モデルのハイパラ探索	既定設定でPersistenceを超えられていない段階で探索に投じるより、変数追加（外気温）の方が期待値が高いと判断。実際に効果が確認された
early stoppingが不要なモデルには学習データを全量渡す	当初は全モデルから一律に検証用2か月を削っていた。修正によりRidgeのMAEが4.39→3.06に改善し、順位が変わった	MAEでのモデル選定	運用指標で順位が逆転するため（p.12）。最終的な推奨は用途ごとに分けた
閾値を時点ごとに動かす	固定閾値ではイベントが0件になり指標が機能しなかった（p.12）		

現時点で言及できない事項

① 気象予報の誤差を織り込んでいない

将来予測で外気温を使う際、**対象時刻の気温が正確に分かる前提**で評価した。実運用では気象予報が入るため、予報誤差のぶん性能は低下する。**本結果は上限値**として読む必要がある。

検証方法：予報履歴を入手するか、予報誤差を模擬したノイズを加えて感度を測る

② 観測地点は推定値

ETDatasetは地点を公開していない。16都市との整合度で武漢を選んだが、武漢0.921と南京0.920はほぼ同点で確定はできない。**実地点が判明すれば相関はさらに上がる可能性が高い。**

③ 単位と機器仕様が不明

データセットに単位の記載がなく、変圧器の定格・冷却方式・容量も不明。そのため**絶対的な危険水準を設定できず**、高温イベントを分布の相対位置（直近30日の上位5%）で定義せざるを得なかった。実運用では機器仕様に基づく閾値に置き換わる。

④ 2台のみの検証

p.14の通り結論が台によって割れる。母数2台では「どちらが一般的か」を判断できない。

⑤ ETTh1のレベルシフトの原因が未特定

2年で夏ピークが36℃→21℃に下がった理由をデータから特定できていない。機器更新・冷却系改修・計測系変更のいずれかと推定されるが、**設備台帳と突き合わせないと確定できない**。この期間をまたいで学習することの妥当性自体が未検証。

⑥ 異常事例での検証ができていない

ナウキャストを異常検知に使う提案をしているが、**データに実際の異常事例（故障・過熱）のラベルがない**。「乖離が出れば異常」という設計の妥当性は、異常ラベル付きデータでの検証を経ていない。

次の打ち手はモデル改良ではなくデータの接続。優先順位は4段階

最優先 気象データの接続

実測（過去分の学習用）と予報（運用時の入力）の両方。本PoCで最も効果が確認された打ち手で、モデル改良より投資効率が高い。予報誤差を織り込んだ再評価もここで行う



次点 計測系の素性確認

記録分解能・サンプリング周期・欠測処理の仕様、および機器の改修履歴。p.14の通り結果を左右する。モデル構築より前に確認すべき項目



用途を2つに絞った第2フェーズ

- ①異常検知の基準線（ナウキャスト）
- ②高温予兆の警報（分位点回帰）。汎用の「油温予測モデル」を作るのではなく、この2用途で運用要件を確定させる



見送り 深層モデルへの投資

現データ規模で優位性なし。台数を横断して学習できる規模になった段階で再評価

第2フェーズで決めるべきこと

- ・見逃し1件と空振り点検1件のコスト比（分位点の設定に直結）
- ・警報のリードタイム要件（1時間先で足りるのか、1週間必要か）
- ・異常検知の乖離しきい値と、異常ラベルによる検証計画

期待できる成果

- ・異常検知：季節・負荷によらない基準線（ETTh2相当の設備で $R^2=0.75$ ）
- ・予兆警報：1週間先の高温を78%捉える（誤報率33%との交換）
- ・いずれも既存の閾値監視では実現できない機能

投資判断としての結論

「油温予測モデルの精度向上」に予算を割く根拠は本検証では得られなかった。同額を気象データの接続と計測系の整備に充てる方が、運用価値への転換率が高いと判断する。

本検証で置いた仮定の一覧

データに関する仮定

仮定	根拠
2016/12/5 09:00~12/7 18:00 の負荷ゼロは欠測である	負荷6変数が同時に厳密な0を取り、かつ同区間で油温が変動を続けている。負荷ゼロで油温が動くのは物理的に説明できない
ETTh1とETTm1は同一変圧器の異なる粒度である	毎正時の値を突き合わせ、全17,420点・全7変数で差が厳密に0であることを確認した
観測地点は華中地方（武漢近傍）である	16都市の気温との整合度で最上位。ただし南京とほぼ同点で確定はできない（限界②）
油温の単位は℃である	データセットに記載はないが、値域と季節変動の振幅が℃として自然。ただし絶対的な危険水準の設定には使えない

タスク設計に関する仮定

仮定	根拠
予測ホライズンは 1 / 24 / 168 時間とする	それぞれ「監視」「翌日の運用計画」「週次の点検計画」という運用単位に対応する。ETT論文の標準設定（24~720）はベンチマーク比較用であり、運用価値の検証には合わない
高温イベントは直近30日の95パーセンタイル超過と定義する	機器仕様が不明で絶対閾値を置けない。時刻tまでの観測のみで計算でき実運用でも成立する
将来予測では対象時刻の外気温が既知とする	実運用では気象予報が相当する。本結果は予報が完全な場合の上限値（限界①）
評価は expanding-window 4分割の平均で行う	単一のhold-outでは評価期間の季節に結論が依存する

実験条件と再現手順

データ分割 (expanding-window)

分割	学習期間	評価期間
fold1	～ 2017/02/26	2017/02/27～06/26
fold2	～ 2017/06/26	2017/06/27～10/26
fold3	～ 2017/10/26	2017/10/27～ 2018/02/26
fold4	～ 2018/02/26	2018/02/27～06/26

特徴量

- **将来予測：162列**／油温のラグ(0～168)・移動統計(3/6/24/168)・差分・移動平均からの乖離、負荷6変数のラグと移動統計、カレンダーの周期エンコード
- **ナウキャスト：191列**／油温由来の列を一切含まない。負荷の指数移動平均（時定数6/24/72/168/720）で熱の蓄積を表現
- **外気温あり：+約120列**／気温・湿度・風速・日射・気圧・降水・雲量・露点のラグと移動統計、中国の法定連休フラグ

主要ハイパーパラメータ

- **LightGBM**：objective=l1（分位点検証時は quantile）, lr=0.05, num_leaves=63, min_data_in_leaf=40, feature_fraction=0.7, early stopping 100
- **DLinear**：入力窓336, 移動平均カーネル25, RevIN 有
- **PatchTST**：入力窓336, patch=16/stride=8, d_model=64, heads=4, layers=2, dropout=0.15, チャンネル独立
- 深層モデルは AdamW + OneCycleLR, 損失L1, 最大40エポック, patience 6

再現手順

```
python -m venv .venv && .venv/bin/pip install -r requirements.txt
PYTHONPATH=src .venv/bin/python src/eda.py # EDA図の生成
PYTHONPATH=src .venv/bin/python src/fetch_weather.py # 外部データ取得と地点推定
PYTHONPATH=src .venv/bin/python src/run_experiment.py --datasets ETTh1 ETTh2 --tasks forecast nowcast [--external]
PYTHONPATH=src .venv/bin/python src/run_deep.py --dataset ETTh1 # DLinear / PatchTST
PYTHONPATH=src .venv/bin/python src/run_quantile.py # 分位点回帰
PYTHONPATH=src .venv/bin/python src/analyze_results.py # 集計と結果図
```

将来予測の全結果（MAE °C・4分割検証の平均）

ETTh1					ETTh2			
モデル	1時間先	24時間先	1週間先	168h改善	モデル	1時間先	24時間先	1週間先
Persistence	0.552	1.933	2.970	基準	Persistence	0.929	3.292	5.467
SeasonalNaive	0.742	2.967	5.085	-71.2%	SeasonalNaive	0.731	4.927	9.210
Ridge	0.621	3.059	5.297	-78.4%	Ridge	0.638	7.552	9.875
PatchTST	0.550	1.975	2.763	+7.0%	LightGBM	0.416	3.283	4.866
DLinear	0.544	1.868	2.761	+7.0%	LightGBM+外気温	0.401	3.122	4.810
LightGBM	0.526	1.925	2.621	+11.8%				
LightGBM+外気温	0.518	1.851	2.469	+16.8%				

2台の比較で見えること

- ETTh2 の1時間先は Persistence 比 +56.9%、ETTh1 は +6.2%。同じ手法で改善幅が9倍違う
- 一方 24時間先はどちらも +4%前後に収束する。短期ほど計測系の差が効き、長期ほど系列の本質的な予測困難さが支配する
- Ridge と SeasonalNaive はどちらの台でも基準線を大きく下回る。線形・周期仮定はこの系列に合わない

運用指標の全結果

高温イベント検知 (ETTh1・1時間先)			
モデル	再現率	適合率	F1
LightGBM+外気温	0.804	0.796	0.800
LightGBM	0.799	0.788	0.793
PatchTST	0.772	0.808	0.789
DLinear	0.753	0.819	0.785
Ridge	0.815	0.749	0.780
Persistence	0.763	0.766	0.765
1時間先では全モデルが F1 0.76~0.80 に収まり差がつかない。学習を入れる必然性は薄い。ナウキャストの結果は p.11 を参照			

分位点回帰の全結果 (ETTh1)				
設定	MAE	再現率	適合率	誤報率
24時間先				
Persistence	1.933	0.439	0.491	3.4%
分位点 0.5	1.840	0.314	0.602	1.5%
分位点 0.7	2.022	0.577	0.460	5.4%
分位点 0.9	2.994	0.932	0.271	24.0%
1週間先				
Persistence	2.970	0.160	0.225	6.2%
分位点 0.5	2.494	0.178	0.340	2.5%
分位点 0.7	2.781	0.368	0.241	8.3%
分位点 0.9	3.997	0.779	0.216	33.2%