

PoC 報告

変圧器 油温予測の技術検証

ETTデータセットを用いて油温の将来予測が
運用・保全判断にどこまで価値を出せるかを検証した

検証対象 : ETTh1 / ETTh2 (1時間粒度・2016年7月～2018年6月)

追加データ : Open-Meteo Historical Weather API (モデル指定なし / Best Match)

検証結果とクライアントの課題への対応

精度の改善幅 / 24時間先 +32% 対象時刻の気象8変数を完全に与えたoracle条件での上限改善 / 1週間先 +36.1% / 実予報での性能は未検証	油温を使わない推定 / ETTh2 R² 0.85 ETTh2 / 油温履歴なし・負荷＋外部気象で観測OTを再構成した精度 / 異常ラベルによる検知性能は未検証	外気温と油温の相関 r = 0.97 ETTh2 / 候補地点の気温と油温の日次共変動 / 共通季節性を含み因果効果や実地点を示す値ではない
--	--	---

基準線が強い理由

油温は自己相関がきわめて高い / 1時間前との相関 0.994
直近値をそのまま返す単純な手法が強い基準線になる
ここを起点にするとモデルの巧拙で得られる上積みは小さい

クライアントの課題との対応

- 課題① 閾値監視の複雑化：負荷＋外部気象による正常値推定の候補 / 異常検知性能は未検証
- 課題② 予防保全への移行：相対高温の再現率と誤報率の交換関係を探求 / 実イベント警報は未検証

次に必要なもの

- 気象データ（実測＋予報）の接続
- 計測系の素性確認（記録分解能・機器改修履歴）
- 台数を増やした再検証

課題文に示された2つの課題に検証タスクを対応

課題文より	
① 負荷変動や外部要因の影響により 温度変動が複雑化している ② 事後対応型の保全から 予測に基づく予防保全へ移行したい	
課題① → タスクA ナウキャスト（同時刻推定）	課題② → タスクB フォーキャスト（将来予測）
問い：油温計を見ずにいま油温が何℃のはずかを当てられるか	問い：h時間後の油温を当てられるか（h = 1 / 24 / 168）
入力：同時刻を含む負荷6変数と外部気象 / <u>油温の履歴は一切使わない</u>	入力：時刻tまでに観測済みの全変数（油温の履歴を含む）
課題への対応：負荷と外部気象から期待温度を推定 / 異常検知に使う正常値モデルの候補を検証	課題への対応：高温域に入る前に点検・負荷抑制の判断材料を出す / 事後対応から予測に基づく保全へ

課題文の但し書きの解釈

「t=Tの油温を予測する際には、t=Tでの特徴量を使用して良い」——この許可で**使える入力が増えるのはタスクAだけ**
同時刻の負荷を使い 油温履歴なしで期待温度を推定できるかを検証
タスクBは時刻tまでの全情報を使うため この許可は入力を何も増やさない
そこで両タスクを分けて 許可が入力を増やす側とそうでない側を切り分けた

欠損・重複ゼロの一方で前処理を要する箇所が3点

負荷は0なのに油温は変動し続ける＝欠測のゼロ埋め



① 欠測・計測異常・停止の疑い（58時間）

2016/12/5 09:00～12/7 18:00 に負荷6変数が**すべて厳密に0**

欠測・計測異常・設備停止のいずれかは設備ログがなく確定できない

対処：疑わしい区間として補間し 当該行を学習・評価から除外

補間方法と周辺窓への影響は感度分析が必要

② 記録分解能の違い

ETTh1の油温は**0.07°C刻みに量子化**されており 2年間で669種類の値しか取らない


ETTh2は0.0005°C刻みで1,628種類 / 同じ「油温」でも計測系が異なる

③ 系列の非定常性

ETTh1は2年間で水準が大きく低下 / 次ページ学習期間と評価期間で分布が異なる

ETTh1は夏のピークが2年で36°C→21°C / 季節性では説明できないレベルシフト

ETTh1は同月比で毎年 5~15°C低下 / ETTh2は年による差がほぼない



事実

ETTh1は**全12か月で前年同月を下回る** / 7月 -12.8°C・8月 -15.0°C

一方ETTh2の前年差は±2°C程度で横ばい
同じ期間・同じ省内の2台で挙動が真逆

負荷では説明できない

同期間 ETTh1の負荷HUFLは**増加** / 2017年1月 8.97 →
2018年1月 10.86

負荷が増えて油温が下がる以上 冷却系の改修・機器更新・計測系の変更といった**系列の外側の要因**を疑うべきだが データからは特定できない

モデリングへの影響


学習期間の平均16.6°Cに対し評価期間は8.6°C

油温の絶対値を学習したモデルは評価期間で系統的に外す
特に勾配ブースティング木は学習データの範囲外へ外挿できない


→ **予測対象を差分に変える設計判断につながる** / p.7

油温は自己履歴が支配的 / 同時刻の負荷による説明力はETTh1で最大 $r=0.22$

1時間前との相関0.994 / 1週間前でも0.83~0.87 = 自己履歴が主要な情報源



同時刻の負荷はOTの水準を最大 $r=0.22$ しか説明せず 変化量では相関が消える



自己相関がきわめて高い

1時間前との相関 0.994 / 24時間前 0.94 / 1週間前でも 0.83~0.87

「直近値をそのまま返す」だけで強力な基準線になることを意味する

これを超えられるかが本PoCの実質的な争点

負荷の説明力が想定より低い

同時刻の相関は最大でHULLの0.22

さらに1階差分をとると相関はほぼ消える / $-0.07 \sim 0.03$

水準の見かけ上の相関は共通の季節変動によるもので 変化の連動はない

ここから立てた仮説

外気温と負荷が油温へ影響するという物理仮説を置くと外部気象を検証する余地がある

相関は共通季節性を含み 因果効果や物理分解を示すものではない

→ 外部データで探索 / p.10


データの性質と設計上の対処

データの性質	設計上の対処	理由
レベルシフト 学習16.6℃ / 評価8.6℃	予測対象を差分 $\Delta = OT(t+h) - OT(t)$ にする	絶対値を学習すると評価期間で系統誤差が出る / 勾配ブースティング木は学習範囲外へ外挿できないため致命的 / 深層モデル側は窓ごとの可逆正規化 RevIN で同じ対処になっている
季節による難易度の差	expanding-window で4分割し全季節を評価	最後の4か月だけで評価すると春～初夏の性能しか見えない / 学習期間を伸ばしながら4か月ずつ評価し結論が特定の季節に依存しないことを確認する
欠測のゼロ埋め	該当58時間を検出して除外	学習・評価の両方から外す / 窓や予測先に区間が重なるサンプルも落とす
自己相関が支配的	Persistenceを常に併走させ これを超えたかで評価する	絶対誤差だけを見ると「MAE 0.5℃」は高精度に見える / 単純手法との差分で語らなければ機械学習を入れる判断ができない

前処理	特徴量	分割	学習	評価
欠測区間の検出と除外 時刻の連続性を確認	ラグ・移動統計・差分 カレンダー周期エンコード 計159～162列	expanding-window 4分割 学習末尾にホライズン分の ギャップを空ける	6モデルを同一条件で比較 early stoppingは 必要なモデルのみ	MAE / RMSE / R ² +高温イベントの検知性能

未来の気象8変数を完全に与えるoracle条件で改善余地 / 24時間先 +32% / 1週間先 +36%

将来の外部気象8変数が完全既知なら / 24時間先 +32% / 1週間先 +36%



ETTh1 の MAE (°C・4分割平均)

モデル	1h	24h	168h
Persistence	0.552	1.933	2.970
SeasonalNaive	0.742	2.967	5.085
Ridge	0.621	3.059	5.297
PatchTST	0.550	1.974	2.763
DLinear	0.544	1.868	2.761
LightGBM	0.526	1.924	2.621
LightGBM+外気温	0.506	1.308	1.898

読み取れること

- 24時間先の上回り幅は完全気象込みで**32.3%** / 外部特徴なしでは**0.5%**
- 1週間先は**36.1%** / 実予報の誤差を含む性能は未検証
- Ridge・SeasonalNaiveは**基準線を大きく下回る**

深層モデルはこのデータ規模で優位性なし / Transformer系はLightGBM比で計算コスト42倍・精度も下回る結果

ETTh1・24時間先の比較

モデル	MAE	学習時間	パラメータ
LightGBM+外気温	1.308	14秒	—
DLinear	1.868	3秒	688
LightGBM	1.924	1.7秒	—
Persistence	1.933	0秒	0
PatchTST	1.974	71.6秒	106,319

なぜこうなるか

学習に使える有効データは1時間粒度で約17,000点 / Transformerが表現力を発揮するには少ない
加えて系列の支配的な構造が「直近値への強い依存+日周期」という単純なもので長距離の依存関係を捉える機構が精度に結びつく場面が乏しい
DLinearがPatchTSTを上回るのは 線形分解モデルが長期予測ベンチマークでTransformerを上回るという既報 Zeng et al., 2023 と整合する

意思決定

現時点で深層モデルへの投資は推奨しない

- 精度で勝てていない
- 推論基盤・再学習運用のコストが増える
- 特徴量重要度のような説明手段が使いにくく 保全現場の納得を得にくい



ただしデータ量が桁で増える場合は再評価に値する / 多数の変圧器を横断学習する等

実装上の補足

DLinear・PatchTSTはいずれも窓ごとの可逆正規化 RevIN を入れており 表形式モデル側で差分を予測しているのと同じ非定常対策を入れている / この処理を外すと両モデルとも大きく劣化する / 学習時間はApple M系GPU（MPS）での実測値


候補地点の気温と油温に強い季節的共変動 $r=0.977$ / 外部気象を探索する根拠

候補地点の気温と油温は強く共変 $r=0.97$ / 共通季節性を含む



出典：Open-Meteo Historical Weather API（モデル指定なし / Best Match, CC BY 4.0）<https://open-meteo.com/en/docs/historical-weather-api> / 16候補中で南京系列が僅差の最上位 / 実地点を同定したものではなく 南京は代表気象プロキシとして採用 / 南京0.919・武漢0.918

負荷＋外部気象による正常値推定候補は ETTh2でR²=0.854 / 異常検知性能は未検証



ナウキャストの精度（油温の履歴を一切使わない）

入力	ETTh1 MAE	ETTh2 MAE	ETTh2 R ²
平均を答えるだけ	6.76	10.18	-1.51
負荷6変数のみ	6.01	6.43	-0.02
負荷＋外部気象	5.10	2.11	0.854

運用上の意味

負荷だけではR²=-0.02 / 外部気象を足すと観測OTの分散の85%を再構成
異常検知に使う期待温度モデルの候補
異常ラベル・残差閾値・誤報率・検知遅延による成立性確認が必要

ETTh1で成立しない理由

ETTh1はR²=-1.66と依然として実用水準にない
p.5で示した2年間のレベルシフトが外気温で説明できないため
機器側の改修や計測系の変更が疑われ その情報なしには基準線を引けない
2台で結論が割れること自体が 導入前に台ごとの素性確認を要することを示す

MAE最適化は閾値超過を捉えにくい / 外部気象の追加で解消

24時間先の高温イベント検知 (ETTh1)				
モデル	MAE	再現率	適合率	F1
LightGBM (外部気象なし)	1.924	0.297	0.538	0.382
Persistence	1.933	0.496	0.555	0.524
SeasonalNaive	2.967	0.702	0.319	0.439
LightGBM+外気温	1.308	0.526	0.692	0.598

なぜ逆転するか

MAEを最小化する学習では モデルは**自信のない場面で平均寄りの無難な値を返す**のが最適になる
その結果 閾値を超える「尖った予測」が出なくなり 見逃しが640件まで増えた
外部気象なしのLightGBMはMAEでPersistenceとほぼ同じ (1.924 対 1.933)なのに 再現率は0.496→0.297へ落ちる
℃単位の誤差が同じでも見逃しは4割増える


評価設計で修正した点

当初は高温イベントの閾値を「学習期間の95パーセンタイル」で固定していたが **p.5のレベルシフト**により評価期間で**該当イベントが1件も発生しない**という不具合が起きた
そこで「**予測時点から見た直近30日の95パーセンタイル**」という時点ごとに動く 閾値に変更
時刻tまでの観測しか使わないため実運用でもそのまま計算でき 「平常時より明確に高い」を季節によらず定義できる

この発見の意味

予測力が足りない状態でMAEだけを最適化すると 警報の用途では基準線を下回る
外部気象を入れて予測力が上がると解消し F1は0.382→0.598へ
精度指標だけでモデルを選ぶと この差が見えない / 次ページは目的関数側からの打ち手

評価期間上で分位点を変えると**相対高温の再現率16%～81%** / 未見性能ではない



やったこと

損失関数を絶対誤差から**分位点損失**に替え 条件付き分布の中央値ではなく**上側**を予測させた
「平均的に何°Cか」ではなく「高い方に振れるとすれば何°Cか」を答えるモデルになる
実装上の変更は目的関数の指定のみ / 特徴量もデータ分割も同一

1週間先の交換レート（ETTh1）

設定	MAE	再現率	誤報率
Persistence	2.970	0.160	6.2%
分位点 0.5	1.873	0.497	4.6%
分位点 0.7	2.019	0.573	6.8%
分位点 0.8	2.199	0.657	9.3%
分位点 0.9	2.711	0.808	16.5%

PoCの成果物として渡すもの

最良の1モデルではなく**この交換レートの表そのもの**を意思決定の材料として提示する
「見逃し1件のコスト」と「空振り点検1件のコスト」の比が分かれば分位点は一意に決まる
その比を持っているのは保全部門であってモデル側ではない

起点軸上の相対高温区間は184区間中93区間を分類 / 実イベント警報ではない

数え方を変えた理由

前ページまでの再現率は**時刻単位**＝「相対高温だった時間の何割を分類できたか」を測っている
ここでは連続する超過時間を1区間としてまとめた / ただし閾値は予測起点時点の履歴から作る探索指標であり **実設備の危険事象や実運用の警報を評価したものではない**

24時間先（ETTh1・イベント174件）				
モデル	分類区間	区間率	予測猶予	超過区間/週
LightGBM+外気温	89	0.51	24h	2.24
Persistence	82	0.47	23.5h	2.76
SeasonalNaive	113	0.65	24h	6.13
LightGBM	57	0.33	23h	1.84


1週間先（ETTh1・イベント184件）				
モデル	分類区間	区間率	予測猶予	超過区間/週
LightGBM+外気温	93	0.51	168h	1.93
Persistence	60	0.33	168h	2.78
SeasonalNaive	97	0.53	168h	5.38
DLinear	3	0.02	168h	0.29

読み取れること

- SeasonalNaiveは区間率が高い（0.53～0.65）が予測超過区間も週5～6回 / 外部特徴量モデルは週約2回
- 外部特徴量モデルは1週間先でも区間率0.51 / ただし実警報の誤報・通知抑制は未評価
- 予測猶予は予測起点から対象時刻までの時間であり **実イベント開始前の初回警報時刻ではない**
- 深層モデルは1週間先でほぼ検知できない（DLinear 3件）

同一手法でも2台で改善幅は+8%と+58% / 1台の検証では判断困難

同じ手法でも1時間先の改善幅は+8%と+58% / 1台の検証では判断できない



1時間先予測の比較

変圧器	Persistence	最良モデル	改善
ETTh1	0.552	0.506	+8.4%
ETTh2	0.929	0.386	+58.4%

差の原因（推定）

記録分解能 / ETTh1の油温は0.07℃刻みに量子化されており 1時間で動く量 中央値0.28℃ に対して刻みが粗い
Persistenceの誤差の相当部分が量子化ノイズで これは学習で減らせない
ETTh2は0.0005℃刻みで滑らかに記録されており 短期の連続的な変化を学習できる

導入判断への含意

- 「ETTで検証したから自社設備でも同じ結果が出る」とは 言えない / 計測系の仕様が結果を左右する
- 導入前に確認すべきはモデルの選択肢ではなく 記録分解能・ サンプル周期・欠測の扱い
- ナウキャストもETTh2で成立しETTh1で不成立 / 台ごとの 素性確認が前提

採った選択6件と見送った選択5件

採った選択	
判断	理由
予測対象を差分にする	レベルシフトへの対処 / 木モデルは学習範囲外へ外挿できない
ナウキャストで油温履歴を禁止する	油温のラグを入れると相関0.994の変数が支配し「負荷から推定できるか」という問い自体が測れなくなる
expanding-window 4分割	最後の4か月だけでは春～初夏の性能しか見えない / 結論が季節に依存しないことを確認する
学習末尾にギャップを空ける	学習行のターゲットが評価区間に食い込むリークを防ぐ
early stoppingが不要なモデルには学習データを全量渡す	当初は全モデルから一律に検証用2か月を削っていた / 修正によりRidgeのMAEが4.39→3.06に改善し順位が変わった
閾値を時点ごとに動かす	固定閾値ではイベントが0件になり指標が機能しなかった (p.12)

あえて採らなかった選択	
見送った案	理由
ホライズン一括の系列出力	ホライズンごとに独立して学習する方式を採用 / 用途に必要な指標も許容誤差も異なり 個別に最適化・評価できる形を優先した
全期間統計での正規化	評価期間の情報が学習に混入する / 分割ごとに閉じた統計のみ使用
ETTm（15分粒度）を主軸にする	ETTthはETTmの毎正時サブサンプルで同一系列であることを確認済み / 粒度を上げてても支配的な構造は変わらず計算コストが4倍になる
深層モデルのハイパラ探索	既定設定でPersistenceを超えられていない段階で探索に投じるより 変数追加の方が期待値が高いと判断 / 実際にMAEが改善した
MAEでのモデル選定	運用指標で順位が逆転するため p.12 / 最終的な推奨は用途ごとに分けた

現時点で言及できない事項

① 実際の気象予報による検証はしていない

将来予測では**対象時刻 t+h の気象8変数が正確に分かる前提**で評価した / 実運用では気象予報が入る改善幅の大半はこの前提に依存する（外部特徴量なしでは24時間先 +0.5%）ため **本結果は完全情報条件の上限値**
検証方法：予報履歴を入手するか 予報誤差を模擬したノイズを加えて感度を測る

④ 2台のみの検証

p.15の通り結論が台によって割れる / 母数2台では「どちらが一般的か」を判断できない

⑦ 設計確定後の独立した評価をしていない

報告値は全期間を4分割した検証の平均で **モデル比較のための交差検証値**
差分ターゲット・外部気象・地点・分位点を選んだ後も同じ期間で報告しているため **設計を固めた後の未見データに対する性能ではない**
本結果は探索的PoCの推定値として読む必要がある

② 観測地点は推定値

ETDatasetは正確な地点を公開していない
16都市との整合度で南京系列を代表プロキシに選んだが 南京0.919と武漢0.918はほぼ同点
所在地の同定結果ではなく 2系列へ同じ地点を使う妥当性も未確認

⑤ ETTh1のレベルシフトの原因が未特定

2年で夏ピークが36℃→21℃に下がった理由をデータから特定できていない
機器更新・冷却系改修・計測系変更のいずれかと推定されるが **設備台帳と突き合わせないと確定できない**
この期間をまたいで学習することの妥当性自体が未検証

⑧ 外部データは再取得で値が変わりうる

掲載結果はリポジトリにコミット済みのCSVを使用している / Open-Meteo Historical Weather APIをモデル指定なし（Best Match）で取得しており **再取得時に数値が変わる可能性がある**
取得日・クエリ条件はコードに記録しているが ハッシュによる固定はしていない

③ 単位と機器仕様が不明

データセットに単位の記載がなく 変圧器の定格・冷却方式・容量も不明
そのため**絶対的な危険水準を設定できず** 高温イベントを分布の相対位置 直近30日の上位5% で定義せざるを得なかった
実運用では機器仕様に基づく閾値に置き換わる

⑥ 異常事例での検証ができていない


ナウキャストを異常検知に使う提案をしているが**データに実際の異常事例のラベルがない**
「乖離が出れば異常」という設計の妥当性は 異常ラベル付きデータでの検証を経ていない

この報告の位置づけ

①と⑦から **本結果は「将来の気象8変数が完全に分かる条件での探索を含んだ推定値」**として扱うべき
導入判断の前に 予報誤差を織り込んだ再評価と 設計を固めた後の独立評価が要る

実際の予報誤差でも改善幅は25～32%残る

実際の予報誤差（1～3℃）でも改善幅は25～32%残る



何を測ったか

前ページまでの改善幅は対象時刻の気象を完全に知るoracle条件で測っている / 実運用で入るのは予報なので その誤差を模擬した
気温予報に標準偏差1～3℃の正規ノイズを与え 改善幅がどこまで残るかを見る
実際の気温予報の誤差は24時間先で1～2℃・1週間先で2～3℃程度

Persistence比の改善率（ETTh1）

予報誤差	24時間先	1週間先
±0℃（oracle）	+31.8%	+35.5%
↓ ±0℃を100としたときの残存率		
±1℃	+30.1%(95%)	+35.4%(100%)
±2℃	+27.5%(87%)	+32.0%(90%)
±3℃	+25.1%（79%）	+30.5%（86%）

この模擬の限界

- 誤差は時刻ごとに独立な正規ノイズ / 実際の予報誤差は**系統的で自己相関を持つ**ため楽観側に振れる可能性
- ノイズを与えたのは気温のみ / 残る7変数と休日は完全既知のまま
- 過去の実予報データによる検証は未実施

完全情報条件で最も誤差が減ったのは外部気象特徴量の追加 / 実予報で再検証が必要

最優先 気象データの再検証 実測と実際の予報履歴の両方 / 本PoCでは完全情報条件で誤差が減ったため 予報誤差を織り込んで効果を確認する	次点 計測系の素性確認 記録分解能・サンプリング周期・欠測処理の仕様および機器の改修履歴 / p.15の通り結果を左右する / モデル構築より前に確認すべき項目	用途を2つに絞った第2フェーズ ①正常値推定からの異常検知候補 ②相対高温から実リスク警報への置換 / 異常ラベルと設備仕様を揃えて成立性を確認する	現時点では保留 深層モデルへの追加投資 本PoCの検証範囲では優位性を確認できず / 台数を横断して学習できる規模になった段階で再評価
---	--	--	---

第2フェーズで決めるべきこと

- 見逃し1件と空振り点検1件のコスト比（分位点の設定に直結）
- 警報のリードタイム要件 / 1時間先で足りるか 1週間必要か
- 異常検知の乖離しきい値と異常ラベルによる検証計画

期待できる成果

- 正常値推定候補：ETTh2で $R^2=0.854$ / 異常検知性能は未評価
- 相対高温：同じ評価期間で再現率16%～81%の交換関係
- 実設備での価値は異常ラベル・危険閾値・予報履歴を用いて確認する

投資判断としての結論

本PoCでは深層モデルへ追加投資する根拠は得られなかった
次の判断材料として 気象予報履歴と計測・設備情報を揃える
検証を優先する

本検証で置いた仮定の一覧

データに関する仮定	
仮定	根拠
2016/12/5 09:00～12/7 18:00の負荷ゼロ区間を 学習から除外 する	6変数が同時に0であり欠測・計測異常・設備停止の可能性 がある / 真因は未確定のため保守的に除外し 補間感度は未 検証
ETTh1とETTM1は 同一変圧器 の異 なる粒度である	毎正時の値を突き合わせ 全17,420点・全7変数で差が厳密 に0であることを確認
南京系列を 代表気象プロキシ として 使う	16都市との整合度で最上位だが武漢とほぼ同点 / 所在地の 同定ではなく 2系列に共通利用する妥当性も未確認＝限界②
油温の単位は ℃ である	データセットに記載はないが値域と季節変動の振幅が℃とし て自然 / ただし絶対的な危険水準の設定には使えない

タスク設計に関する仮定	
仮定	根拠
予測ホライズンは 1 / 24 / 168 時間 とする	それぞれ「監視」「翌日の運用計画」「週次の点検計画」とい う運用単位に対応 / ETT論文の標準設定 24～720 はベンチ マーク比較用であり運用価値の検証には合わない
相対高温を 直近30日の95パーセン タイル超過 と定義する	機器仕様が不明なため置いた比較用の探索指標 / 実設備の危 険閾値ではない
将来予測では対象時刻 t+h の気象8 変数が既知 とする	予報列と実測列はコード上で分離 (wx_fc_ / wx_obs_) / 実予報の誤差を含まない完全情報条件の上限値＝限界①
評価は expanding-window 4分 割 の平均で行う	単一のhold-outでは評価期間の季節に結論が依存する

実験条件と再現手順

データ分割 (expanding-window)			特徴量	主要ハイパーパラメータ
分割	学習期間	評価期間	• 将来予測：162列／油温のラグ(0～168)・移動統計 (3/6/24/168)・差分・移動平均からの乖離 / 負荷6変数のラグと移動統計 / カレンダーの周期エンコード • ナウキャスト：191列／油温由来の列を一切含まない / 負荷の指数移動平均 時定数6/24/72/168/720 で熱の蓄積を表現 • 外部気象あり：+約120列／気温・湿度・風速・日射・気圧・降水・雲量・露点のラグと移動統計 / 中国の法定連休フラグ	• LightGBM：objective=l1（分位点検証時はquantile）, lr=0.05, num_leaves=63, min_data_in_leaf=40, feature_fraction=0.7, early stopping 100 • DLinear：入力窓336, 移動平均カーネル25, RevIN有 • PatchTST：入力窓336, patch=16/stride=8, d_model=64, heads=4, layers=2, dropout=0.15, チャンネル独立 • 深層モデルは AdamW + OneCycleLR, 損失L1, 最大40エポック, patience 6
各分割の学習末尾2か月をearly stopping用の検証に充て 学習末尾からホライズン分のギャップを空けている				

再現手順

```
python -m venv .venv && .venv/bin/pip install -r requirements.txt
PYTHONPATH=src .venv/bin/python src/eda.py # EDA図の生成
PYTHONPATH=src .venv/bin/python src/fetch_weather.py # 外部データ取得と地点推定
PYTHONPATH=src .venv/bin/python src/run_experiment.py --datasets ETTh1 ETTh2 --tasks forecast nowcast [--external]
PYTHONPATH=src .venv/bin/python src/run_deep.py --dataset ETTh1 # DLinear / PatchTST
PYTHONPATH=src .venv/bin/python src/run_quantile.py # 分位点回帰
PYTHONPATH=src .venv/bin/python src/analyze_results.py # 集計と結果図
```

将来予測の全結果（MAE °C・4分割検証の平均）

ETTh1				
モデル	1時間先	24時間先	1週間先	168h改善
Persistence	0.552	1.933	2.970	基準
SeasonalNaive	0.742	2.967	5.085	-71.2%
Ridge	0.621	3.059	5.297	-78.4%
PatchTST	0.550	1.974	2.763	+7.0%
DLinear	0.544	1.868	2.761	+7.0%
LightGBM	0.526	1.924	2.621	+11.8%
LightGBM+外気温	0.506	1.308	1.898	+36.1%

ETTh2			
モデル	1時間先	24時間先	1週間先
Persistence	0.929	3.292	5.467
SeasonalNaive	0.731	4.927	9.210
Ridge	0.638	7.552	9.874
LightGBM	0.416	3.283	4.866
LightGBM+外気温	0.386	2.090	2.892

2台の比較で見えること

- ETTh2 の1時間先は Persistence 比 +58.4% / ETTh1 は +8.4% / 同じ手法で改善幅が7倍違う
- 24時間先は外部気象込みでどちらも +32~37% / 外部気象なしでは両方 +0.5%未満に落ちる
- Ridge と SeasonalNaive はどちらの台でも基準線を大きく下回る / 線形・周期仮定はこの系列に合わない

運用指標の全結果

高温イベント検知（ETTh1・1時間先）			
モデル	再現率	適合率	F1
LightGBM+外気温	0.811	0.800	0.806
LightGBM	0.799	0.788	0.793
PatchTST	0.772	0.808	0.789
DLinear	0.753	0.819	0.785
Ridge	0.815	0.749	0.780
Persistence	0.763	0.766	0.765
1時間先では全モデルが F1 0.76～0.81 に収まり差がつかない / 学習を入れる必然性は薄い / ナウキャストの結果は p.11 を参照			

分位点回帰の全結果（ETTh1）				
設定	MAE	再現率	適合率	誤報率
24時間先				
Persistence	1.933	0.439	0.491	3.4%
分位点 0.5	1.323	0.531	0.633	2.2%
分位点 0.7	1.496	0.691	0.551	4.3%
分位点 0.9	2.350	0.924	0.348	16.5%
1週間先				
Persistence	2.970	0.160	0.225	6.2%
分位点 0.5	1.873	0.497	0.519	4.6%
分位点 0.7	2.019	0.573	0.433	6.8%
分位点 0.9	2.711	0.808	0.328	16.5%