

PoC 報告

変圧器 油温予測の技術検証

ETTデータセットを用いて油温の将来予測が
運用・保全判断にどこまで価値を出せるかを検証した

検証対象 : ETTh1 / ETTh2 (1時間粒度・2016年7月~2018年6月)
追加データ : Open-Meteo Historical Weather API (ERA5 再解析)

検証結果とクライアントの課題への対応

精度の改善幅 / 24時間先 +0.5% 24時間先の予測で162個の特徴量を使った学習モデルが「今と同じ温度」と言い張るだけの手法に対して得た改善幅 / 1週間先でも上限は +16.8%	油温を使わない推定 / ETTh2 R² 0.75 ETTh2 / 油温センサを一切使わず負荷+外気温だけで推定した精度 / 負荷のみでは R²=-0.02 で平均予測と同等	外気温と油温の相関 r = 0.96 外気温と油温の相関 / データに含まれる負荷6変数の相関は最大 0.22 / 最も説明力の高い変数が最初から入っていない
---	--	--

基準線が強い理由

油温は自己相関がきわめて高い / 1時間前との相関 0.994
直近値をそのまま返す単純な手法が強い基準線になる
ここを起点にするとモデルの巧拙で得られる上積みは小さい

クライアントの課題との対応

- 課題① 閾値監視の複雑化：負荷と外気温から正常温度を推定 / ETTh2 で R²=0.75・ETTh1 で -1.75
- 課題② 予防保全への移行：1週間先の高温検知は再現率 0.779 / 誤報率 33.2%

次に必要なもの

- 気象データ（実測+予報）の接続
- 計測系の素性確認（記録分解能・機器改修履歴）
- 台数を増やした再検証

課題文に示された2つの課題に検証タスクを対応

課題文より

- ① 負荷変動や外部要因の影響により 温度変動が複雑化している ② 事後対応型の保全から 予測に基づく予防保全へ移行したい

課題① → タスクA ナウキャスト（同時刻推定）

問い：油温計を見ずにいま油温が何℃のはずかを当てられるか

入力：同時刻を含む負荷6変数と外気温 / 油温の履歴は一切使わない

課題への対応：負荷と外気温から「この条件での正常温度」を推定 / 固定閾値と違い季節と負荷条件によらず乖離を検出できる

課題② → タスクB フォーキャスト（将来予測）

問い：h時間後の油温を当てられるか（h = 1 / 24 / 168）

入力：時刻tまでに観測済みの全変数（油温の履歴を含む）

課題への対応：高温域に入る前に点検・負荷抑制の判断材料を出す / 事後対応から予測に基づく保全へ

課題文の但し書きの解釈

「t=Tの油温を予測する際には、t=Tでの特徴量を使用して良い」——この許可で**使える入力が増えるのはタスクAだけ**

同時刻の負荷を使えるからこそ「今この瞬間の正常温度」を推定でき 異常検知の基準線が成立する

タスクBは時刻tまでの全情報を使うため この許可は入力を何も増やさない

そこで両タスクを分けて 許可が入力を増やす側とそうでない側を切り分けた

欠損・重複ゼロの一方で前処理を要する箇所が3点

負荷は0なのに油温は変動し続ける＝欠測のゼロ埋め



① 欠測のゼロ埋め (58時間)

2016/12/5 09:00～12/7 18:00 に負荷6変数が**すべて厳密に0**

同区間で油温だけは $-4.1 \sim 15.3^{\circ}\text{C}$ の範囲で変動を続けている

負荷ゼロで油温が動くのは物理的に説明がつかず 実測ではなく埋め値と判断

対処：該当区間を欠測として扱い線形補間したうえで学習・評価の対象から除外

ゼロのまま移動平均に流すと前後数日ぶんの特徴量まで汚染される

② 記録分解能の違い

ETTh1の油温は **0.07°C 刻みに量子化**されており 2年間で669種類の値しか取らない


ETTh2は 0.0005°C 刻みで1,628種類 / 同じ「油温」でも計測系が異なる

③ 系列の非定常性

ETTh1は2年間で水準が大きく低下 / 次ページ学習期間と評価期間で分布が異なる

ETTh1は夏のピークが2年で36°C→21°C / 季節性では説明できないレベルシフト

ETTh1は同月比で毎年 5~15°C低下 / ETTh2は年による差がほぼない



事実

ETTh1は**全12か月で前年同月を下回る** / 7月 -12.8°C・8月 -15.0°C

一方ETTh2の前年差は±2°C程度で横ばい
同じ期間・同じ省内の2台で挙動が真逆

負荷では説明できない

同期間 ETTh1の負荷HUFLは**増加** / 2017年1月 8.97 →
2018年1月 10.86

負荷が増えて油温が下がる以上 冷却系の改修・機器更新・計測系の変更といった**系列の外側の要因**を疑うべきだが データからは特定できない

モデリングへの影響


学習期間の平均16.6°Cに対し評価期間は8.6°C

油温の絶対値を学習したモデルは評価期間で系統的に外す
特に勾配ブースティング木は学習データの範囲外へ外挿できない


→ **予測対象を差分に変える設計判断につながる** / p.7

油温は自己履歴が支配的 / 同時刻の負荷による説明力は最大 $r=0.22$

1時間前との相関0.994 / 1週間前でも0.83~0.87 = 自己履歴が主要な情報源



同時刻の負荷はOTの水準を最大 $r=0.22$ しか説明せず 変化量では相関が消える



自己相関がきわめて高い

1時間前との相関 0.994 / 24時間前 0.94 / 1週間前でも 0.83~0.87

「直近値をそのまま返す」だけで強力な基準線になることを意味する

これを超えられるかが本PoCの実質的な争点

負荷の説明力が想定より低い

同時刻の相関は最大でHULLの0.22

さらに1階差分をとると相関はほぼ消える / $-0.07 \sim 0.03$

水準の見かけ上の相関は共通の季節変動によるもので 変化の連動はない

ここから立てた仮説

油温 $\equiv$ 外気温 + 負荷による温度上昇 という物理を踏まえると最も説明力が高いはずの変数がデータに入っていない

日内パターン（早朝に最低・午後に最高）も外気温の形そのものの

→ 外部データで検証 / p.10


データの性質と設計上の対処

データの性質	設計上の対処	理由
レベルシフト 学習16.6℃ / 評価8.6℃	予測対象を差分 $\Delta = OT(t+h) - OT(t)$ にする	絶対値を学習すると評価期間で系統誤差が出る / 勾配ブースティング木は学習範囲外へ外挿できないため致命的 / 深層モデル側は窓ごとの可逆正規化 RevIN で同じ対処になっている
季節による難易度の差	expanding-window で4分割し全季節を評価	最後の4か月だけで評価すると春～初夏の性能しか見えない / 学習期間を伸ばしながら4か月ずつ評価し結論が特定の季節に依存しないことを確認する
欠測のゼロ埋め	該当58時間を検出して除外	学習・評価の両方から外す / 窓や予測先に区間が重なるサンプルも落とす
自己相関が支配的	Persistenceを常に併走させ これを超えたかで評価する	絶対誤差だけを見ると「MAE 0.5℃」は高精度に見える / 単純手法との差分で語らなければ機械学習を入れる判断ができない

前処理	特徴量	分割	学習	評価
欠測区間の検出と除外 時刻の連続性を確認	ラグ・移動統計・差分 カレンダー周期エンコード 計159～162列	expanding-window 4分割 学習末尾にホライズン分の ギャップを空ける	6モデルを同一条件で比較 early stoppingは 必要なモデルのみ	MAE / RMSE / R² +高温イベントの検知性能

基準線を明確に上回るのは1週間先のみ / 24時間先はほぼ横並び

学習ありで基準を明確に上回るのは1週間先だけ / 24時間先は横並び



ETTh1 の MAE (°C・4分割平均)

モデル	1h	24h	168h
Persistence	0.552	1.933	2.970
SeasonalNaive	0.742	2.967	5.085
Ridge	0.621	3.059	5.297
PatchTST	0.550	1.974	2.763
DLinear	0.544	1.868	2.761
LightGBM	0.526	1.924	2.621
LightGBM+外気温	0.518	1.851	2.469

読み取れること

- 24時間先の上回り幅は4.2%で誤差の範囲
- 1週間先は16.8%改善 / 長期ほど学習の価値が出る
- Ridge・SeasonalNaiveは基準線を大きく下回る

深層モデルはこのデータ規模で優位性なし / Transformer系は計算コスト14倍で精度も下回る結果

ETTh1・24時間先の比較			
モデル	MAE	学習時間	パラメータ
LightGBM+外気温	1.851	14秒	—
DLinear	1.868	3秒	688
LightGBM	1.924	7秒	—
Persistence	1.933	0秒	0
PatchTST	1.974	100秒	106,319

なぜこうなるか

学習に使える有効データは1時間粒度で約17,000点 / Transformerが表現力を発揮するには少ない
加えて系列の支配的な構造が「直近値への強い依存+日周期」という単純なもので長距離の依存関係を捉える機構が精度に結びつく場面が乏しい
DLinearがPatchTSTを上回るの は 線形分解モデルが長期予測ベンチマークでTransformerを上回るという既報 Zeng et al., 2023 と整合する

意思決定

現時点で深層モデルへの投資は推奨しない

- 精度で勝てていない
- 推論基盤・再学習運用のコストが増える
- 特徴量重要度のような説明手段が使いにくく保全現場の納得を得にくい



ただしデータ量が桁で増える場合は再評価に値する / 多数の変圧器を横断学習する等

実装上の補足

DLinear・PatchTSTはいずれも窓ごとの可逆正規化 RevIN を入れており 表形式モデル側で差分を予測しているのと同じ非定常対策を入れている / この処理を外すと両モデルとも大きく劣化する / 学習時間はApple M系GPU（MPS）での実測値

油温を最も説明する変数は外気温 $r=0.96$ / データセットには非収録


油温を最も説明する変数は外気温 $r=0.96$ / これはデータに入っていなかった



出典：Open-Meteo Historical Weather API (ERA5 再解析, CC BY 4.0 / Copernicus Climate Change Service) <https://open-meteo.com/en/docs/historical-weather-api> / ETDatasetは観測地点を「中国のある省の2地域」としか公開していないため 気候帯を広くとった16都市の気温との整合度で地点を推定 / 整合度は日次相関・季節周期を除いた残差相関・日内パターンの相関の平均 / 武漢0.921・南京0.920が同点上位

外気温の追加で油温を用いない推定は ETTh2 で $R^2=0.75$ / ETTh1 では -1.75

外気温を足すとETTh2の油温推定はMAE 3.2℃ / 平均予測の3分の1



ナウキャストの精度（油温の履歴を一切使わない）

入力	ETTh1 MAE	ETTh2 MAE	ETTh2 R ²
平均を答えるだけ	6.76	10.18	-1.51
負荷6変数のみ	6.01	6.43	-0.02
負荷+外気温	5.07	3.23	0.75

運用上の意味

負荷だけでは平均を答えるのと同じ $R^2=-0.02$ だったものが外気温を足すと分散の75%を説明できるようになる
これは「この負荷・この外気温なら油温は何℃が正常か」という基準線が引けることを意味する
実測との乖離を監視すれば 固定閾値では不可能な季節・負荷条件によらない異常検知が成立する

ETTh1で成立しない理由

ETTh1は $R^2=-1.75$ と依然として実用水準にない
p.5で示した2年間のレベルシフトが外気温で説明できないため
機器側の改修や計測系の変更が疑われ その情報なしには基準線を引けない
2台で結論が割れること自体が 導入前に台ごとの素性確認が要することを示す

精度指標で最良のモデルが 警報の用途では基準線を下回る結果

24時間先の高温イベント検知（ETTh1）

モデル	MAE	再現率	適合率	F1
LightGBM（MAE最適化）	1.839	0.314	0.602	0.388
Persistence	1.933	0.439	0.491	0.463
SeasonalNaive	2.967	0.702	0.319	0.439

なぜ逆転するか

MAEを最小化する学習では モデルは**自信のない場面で平均寄りの無難な値を返す**のが最適になる
その結果 閾値を超える「尖った予測」が出なくなり 見逃しが640件まで増えた
精度指標と運用指標は同じ方向を向いていない
℃単位の誤差0.09℃の改善は保全判断を何も変えないが 再現率0.44→0.31の悪化は「見逃しが4割増える」ことを意味する


評価設計で修正した点

当初は高温イベントの閾値を「学習期間の95パーセンタイル」で固定していたが **p.5のレベルシフト**により評価期間で**該当イベントが1件も発生しない**という不具合が起きた
そこで「**予測時点から見た直近30日の95パーセンタイル**」という時点ごとに動く閾値に変更
時刻tまでの観測しか使わないため実運用でもそのまま計算でき 「平常時より明確に高い」を季節によらず定義できる

この発見の意味

PoCの評価指標をMAEだけに置いていたら「**LightGBMが最良**」という誤った結論を報告していた
運用でどう使うかを決めてから指標を決める必要がある / 次ページはこの発見を受けた打ち手

目的関数を運用指標に合わせると1週間先の高温検知は16%→78%



やったこと

損失関数を絶対誤差から**分位点損失**に替え 条件付き分布の中央値ではなく**上側**を予測させた
「平均的に何℃か」ではなく「高い方に振れるとすれば何℃か」を答えるモデルになる
実装上の変更は目的関数の指定のみ / 特徴量もデータ分割も同一

1週間先の交換レート（ETTh1）


設定	MAE	再現率	誤報率
Persistence	2.970	0.160	6.2%
分位点 0.5	2.494	0.178	2.5%
分位点 0.7	2.781	0.367	8.3%
分位点 0.8	3.028	0.469	12.5%
分位点 0.9	3.997	0.779	33.2%

PoCの成果物として渡すもの

最良の1モデルではなく**この交換レートの表そのもの**を意思決定の材料として提示する
「見逃し1件のコスト」と「空振り点検1件のコスト」の比が分かれば分位点は一意に決まる
その比を持っているのは保全部門であってモデル側ではない

同一手法でも2台で改善幅は+6%と+57% / 1台の検証では判断困難

同じ手法でも1時間先の改善幅は+6%と+57% / 1台の検証では判断できない



1時間先予測の比較

変圧器	Persistence	最良モデル	改善
ETTh1	0.552	0.518	+6.2%
ETTh2	0.929	0.401	+56.9%

差の原因（推定）

記録分解能 / ETTh1の油温は0.07℃刻みに量子化されており1時間で動く量 中央値0.28℃ に対して刻みが粗い
Persistenceの誤差の相当部分が量子化ノイズで これは学習で減らせない
ETTh2は0.0005℃刻みで滑らかに記録されており 短期の連続的な変化を学習できる

導入判断への含意

- 「ETTで検証したから自社設備でも同じ結果が出る」とは言えない / 計測系の仕様が結果を左右する
- 導入前に確認すべきはモデルの選択肢ではなく記録分解能・サンプリング周期・欠測の扱い
- ナウキャストもETTh2で成立しETTh1で不成立 / 台ごとの素性確認が前提

採った選択6件と見送った選択5件

採った選択	
判断	理由
予測対象を差分にする	レベルシフトへの対処 / 木モデルは学習範囲外へ外挿できない
ナウキャストで油温履歴を禁止する	油温のラグを入れると相関0.994の変数が支配し「負荷から推定できるか」という問い自体が測れなくなる
expanding-window 4分割	最後の4か月だけでは春～初夏の性能しか見えない / 結論が季節に依存しないことを確認する
学習末尾にギャップを空ける	学習行のターゲットが評価区間に食い込むリークを防ぐ
early stoppingが不要なモデルには学習データを全量渡す	当初は全モデルから一律に検証用2か月を削っていた / 修正によりRidgeのMAEが4.39→3.06に改善し順位が変わった
閾値を時点ごとに動かす	固定閾値ではイベントが0件になり指標が機能しなかった (p.12)

あえて採らなかった選択	
見送った案	理由
ホライズン一括の系列出力	ホライズンごとに独立して学習する方式を採用 / 用途に必要な指標も許容誤差も異なり 個別に最適化・評価できる形を優先した
全期間統計での正規化	評価期間の情報が学習に混入する / 分割ごとに閉じた統計のみ使用
ETTm（15分粒度）を主軸にする	ETTthはETTmの毎正時サブサンプルで同一系列であることを確認済み / 粒度を上げても支配的な構造は変わらず計算コストが4倍になる
深層モデルのハイパラ探索	既定設定でPersistenceを超えられていない段階で探索に投じるより 変数追加の方が期待値が高いと判断 / 実際にMAEが改善した
MAEでのモデル選定	運用指標で順位が逆転するため p.12 / 最終的な推奨は用途ごとに分けた

現時点で言及できない事項

① 気象予報の誤差を織り込んでいない

将来予測で外気温を使う際 **対象時刻の気温が正確に分かる前提**で評価した
実運用では気象予報が入るため予報誤差のぶん性能は低下する
/ **本結果は上限値**として読む必要がある
検証方法：予報履歴を入手するか 予報誤差を模擬したノイズを加えて感度を測る

④ 2台のみの検証

p.14の通り結論が台によって割れる / 母数2台では「どちらが一般的か」を判断できない

② 観測地点は推定値

ETDatasetは地点を公開していない
16都市との整合度で武漢を選んだが 武漢0.921と南京0.920はほぼ同点で確定はできない
実地点が判明すれば相関はさらに上がる可能性が高い

⑤ ETTh1のレベルシフトの原因が未特定

2年で夏ピークが36℃→21℃に下がった理由をデータから特定できていない
機器更新・冷却系改修・計測系変更のいずれかと推定されるが **設備台帳と突き合わせないと確定できない**
この期間をまたいで学習することの妥当性自体が未検証

③ 単位と機器仕様が不明

データセットに単位の記載がなく 変圧器の定格・冷却方式・容量も不明
そのため**絶対的な危険水準を設定できず** 高温イベントを分布の相対位置 直近30日の上位5% で定義せざるを得なかった
実運用では機器仕様に基づく閾値に置き換わる

⑥ 異常事例での検証ができていない

ナウキャストを異常検知に使う提案をしているが**データに実際の異常事例のラベルがない**
「乖離が出れば異常」という設計の妥当性は 異常ラベル付きデータでの検証を経ていない

追加検証で最も誤差が減ったのは外気温の接続 / 優先順位は4段階

最優先 気象データの接続 実測と予報の両方 / 本PoCで最も誤差が減った検証でモデル改良より結果につながる / 予報誤差を織り込んだ再評価もここで行う	次点 計測系の素性確認 記録分解能・サンプリング周期・欠測処理の仕様および機器の改修履歴 / p.14の通り結果を左右する / モデル構築より前に確認すべき項目	用途を2つに絞った第2フェーズ ①異常検知の基準線＝ナウキャスト ②高温予兆の警報＝分位点回帰 / 汎用の「油温予測モデル」を作るのではなくこの2用途で運用条件を決める	見送り 深層モデルへの投資 現データ規模で優位性なし / 台数を横断して学習できる規模になった段階で再評価
--	--	--	---

第2フェーズで決めるべきこと

- 見逃し1件と空振り点検1件のコスト比（分位点の設定に直結）
- 警報のリードタイム要件 / 1時間先で足りるか 1週間必要か
- 異常検知の乖離しきい値と異常ラベルによる検証計画

期待できる成果

- 異常検知：季節・負荷によらない基準線（ETTh2相当の設備で $R^2=0.75$ ）
- 予兆警報：1週間先の高温を78%捉える（誤報率33%との交換）
- いずれも既存の閾値監視では実現できない機能

投資判断としての結論

本検証では予測精度の向上に予算を割く根拠は得られなかった
同額を気象データの接続と計測系の整備に充てる方が結果につながると判断する

本検証で置いた仮定の一覧

データに関する仮定	
仮定	根拠
2016/12/5 09:00～12/7 18:00 の負荷ゼロは 欠測 である	負荷6変数が同時に厳密な0を取り かつ同区間で油温が変動を続けている / 負荷ゼロで油温が動くのは物理的に説明できない
ETTh1とETTm1は 同一変圧器 の異なる粒度である	毎正時の値を突き合わせ 全17,420点・全7変数で差が厳密に0であることを確認
観測地点は 華中地方（武漢近傍） である	16都市の気温との整合度で最上位 / ただし南京とほぼ同点で確定はできない＝限界②
油温の単位は ℃ である	データセットに記載はないが値域と季節変動の振幅が℃として自然 / ただし絶対的な危険水準の設定には使えない

タスク設計に関する仮定	
仮定	根拠
予測ホライズンは 1 / 24 / 168 時間 とする	それぞれ「監視」「翌日の運用計画」「週次の点検計画」という運用単位に対応 / ETT論文の標準設定 24～720 はベンチマーク比較用であり運用価値の検証には合わない
高温イベントは 直近30日の95パーセンタイル超過 と定義する	機器仕様が不明で絶対閾値を置けない / 時刻tまでの観測のみで計算でき実運用でも成立する
将来予測では対象時刻の 外気温が既知 とする	実運用では気象予報が相当する / 本結果は予報が完全な場合の上限値＝限界①
評価は expanding-window 4分割 の平均で行う	単一のhold-outでは評価期間の季節に結論が依存する

実験条件と再現手順

データ分割 (expanding-window)			特徴量	主要ハイパーパラメータ
分割	学習期間	評価期間	• 将来予測：162列／油温のラグ(0～168)・移動統計 (3/6/24/168)・差分・移動平均からの乖離 / 負荷6変数のラグと移動統計 / カレンダーの周期エンコード • ナウキャスト：191列／油温由来の列を一切含まない / 負荷の指数移動平均 時定数6/24/72/168/720 で熱の蓄積を表現 • 外気温あり：+約120列／気温・湿度・風速・日射・気圧・降水・雲量・露点のラグと移動統計 / 中国の法定連休フラグ	• LightGBM：objective=l1（分位点検証時はquantile）, lr=0.05, num_leaves=63, min_data_in_leaf=40, feature_fraction=0.7, early stopping 100 • DLinear：入力窓336, 移動平均カーネル25, RevIN有 • PatchTST：入力窓336, patch=16/stride=8, d_model=64, heads=4, layers=2, dropout=0.15, チャンネル独立 • 深層モデルは AdamW + OneCycleLR, 損失L1, 最大40エポック, patience 6
各分割の学習末尾2か月をearly stopping用の検証に充て 学習末尾からホライズン分のギャップを空けている				

再現手順

```
python -m venv .venv && .venv/bin/pip install -r requirements.txt
PYTHONPATH=src .venv/bin/python src/eda.py # EDA図の生成
PYTHONPATH=src .venv/bin/python src/fetch_weather.py # 外部データ取得と地点推定
PYTHONPATH=src .venv/bin/python src/run_experiment.py --datasets ETTh1 ETTh2 --tasks forecast nowcast [--external]
PYTHONPATH=src .venv/bin/python src/run_deep.py --dataset ETTh1 # DLinear / PatchTST
PYTHONPATH=src .venv/bin/python src/run_quantile.py # 分位点回帰
PYTHONPATH=src .venv/bin/python src/analyze_results.py # 集計と結果図
```

将来予測の全結果（MAE °C・4分割検証の平均）

ETTh1				
モデル	1時間先	24時間先	1週間先	168h改善
Persistence	0.552	1.933	2.970	基準
SeasonalNaive	0.742	2.967	5.085	-71.2%
Ridge	0.621	3.059	5.297	-78.4%
PatchTST	0.550	1.974	2.763	+7.0%
DLinear	0.544	1.868	2.761	+7.0%
LightGBM	0.526	1.924	2.621	+11.8%
LightGBM+外気温	0.518	1.851	2.469	+16.8%

ETTh2			
モデル	1時間先	24時間先	1週間先
Persistence	0.929	3.292	5.467
SeasonalNaive	0.731	4.927	9.210
Ridge	0.638	7.552	9.874
LightGBM	0.416	3.283	4.866
LightGBM+外気温	0.401	3.122	4.810

2台の比較で見えること

- ETTh2 の1時間先は Persistence 比 +56.9% / ETTh1 は +6.2% / 同じ手法で改善幅が9倍違う
- 一方 24時間先はどちらも +4%前後に収束 / 短期ほど計測系の差が誤差を左右し 長期ほど系列の本質的な予測困難さが支配する
- Ridge と SeasonalNaive はどちらの台でも基準線を大きく下回る / 線形・周期仮定はこの系列に合わない

運用指標の全結果

高温イベント検知（ETTh1・1時間先）			
モデル	再現率	適合率	F1
LightGBM+外気温	0.804	0.796	0.800
LightGBM	0.799	0.788	0.793
PatchTST	0.772	0.808	0.789
DLinear	0.753	0.819	0.785
Ridge	0.815	0.749	0.780
Persistence	0.763	0.766	0.765
1時間先では全モデルが F1 0.76～0.80 に収まり差がつかない / 学習を入れる必然性は薄い / ナウキャストの結果は p.11 を参照			

分位点回帰の全結果（ETTh1）				
設定	MAE	再現率	適合率	誤報率
24時間先				
Persistence	1.933	0.439	0.491	3.4%
分位点 0.5	1.839	0.314	0.602	1.5%
分位点 0.7	2.022	0.577	0.460	5.4%
分位点 0.9	2.994	0.932	0.271	24.0%
1週間先				
Persistence	2.970	0.160	0.225	6.2%
分位点 0.5	2.494	0.178	0.340	2.5%
分位点 0.7	2.781	0.367	0.241	8.3%
分位点 0.9	3.997	0.779	0.216	33.2%